

华东师范大学

本科生创新训练培育项目（创新训练类）

立项申请书

项目名称：OSS-Mentor：基于开发者成长画像的开源贡献导学系统

项目负责人：朱翎融

项目所在单位：数据科学与工程学院

项目指导教师：陆雪松

立项申请时间：2026 年 5 月 9 日

华东师范大学本科生院编制

一、基本情况

项目起止时间	2026. 5-2027. 5			
项目负责人	姓 名	朱翎融	学 号	10245501401
	性 别	女	年 级	2024 级
	院 系	数据科学与工程学院	专 业	数据科学与大数据技术
	手 机	18019477670	E- mail	10245501401@stu.ecn u. edu. cn
	入校以来专业必修课成绩	课程名称	学分	成绩
		数据结构初步	2	85
		程序设计	3	75
		Web 编程	2	87
		算法基础	4	93
		概率论与数理统计	4	76
		数据科学与工程数学基础	4	89
		数据科学与工程导论	3	优
		计算机系统	5	77
		专业英语	1	优
曾经参与科研情况	无			
项目性质	☐小发明、小创作、小设计等 ☐开放实验室或实习基地中的创新性实验或新实验开发 ☐基础性研究 ☒应用性研究 ☐社会调研 ☐教育教学研习项目			
项目选题来源	☒自主立题 ☐教师科研课题的子项目			

项目受其他渠道资助情况	“无”或“具体资助来源和经费”，包括曾获奖情况 无
-------------	------------------------------

二、立项背景及依据

包括研究目的、国内外研究现状分析与评价、研究意义，应附主要参考文献及出处

1. 研究目的

开源软件（OSS）已成为全球数字基础设施的核心支柱，GitHub 平台数据显示，全球超 3.6 万个开源项目依赖于排名前 50 的核心开源项目。然而，开源社区长期面临新人准入门槛高、任务匹配精准度低、开发者留存率不足的痛点：超过 60%的首次贡献者因找不到合适任务、不熟悉贡献流程或无法解决技术障碍而放弃参与；现有项目支持多为通用化文档，缺乏针对开发者个体能力与成长阶段的个性化引导；进阶开发者则难以获得与自身专业方向匹配的深度任务，导致人才潜力无法充分释放。

本项目旨在研发 OSS-Mentor 开源贡献导学系统，通过构建多维度开发者成长画像，结合开源任务特征分析与深度学习、大模型等技术，实现从"新手破冰"到"深度贡献"的全生命周期个性化引导。具体目标包括：

- 建立覆盖教育背景、技术栈、贡献历史、协作能力等维度的开发者成长画像体系，实现对开发者能力与兴趣的精准刻画；
- 基于大规模首次贡献实证数据，识别入门级贡献任务的特征与技能要求，为零基础开发者提供低门槛、高成功率的破冰任务匹配；
- 融合 CodeBERT 代码语义建模、图神经网络及大模型技术，构建面向进阶开发者的任务推荐框架，生成与能力匹配的阶梯式成长路径；
- 开发开源贡献导学系统，通过示范应用验证系统在降低入门门槛、提升开发者留存率与开源协作效率方面的实际效果。

2. 国内外研究现状分析与评价

2.1 开源新人贡献特征与入门障碍研究

学术界对开源新人首次贡献的特征与障碍已开展大量实证研究。Subramanian 等人^[1]对 Apache 基金会 1000 个项目中 3501 名开发者的首次 PR 进行分析，发现：（1）语言分布上，Java 是首次贡献最常用的语言（34.67%），而 C++ 仅占 0.83%；（2）贡献类型上，非代码贡献占比显著，PNG 图片（5.92%）和 Markdown 文档（4.57%）分别位列第三、第四；（3）贡献规模上，31.5%的首次 PR 仅修改 1-5 行代码，54.77%为单文件修改，中位数修改量为 15 行。该研究揭示了文档修复、轻量代码修改、资源补充是最适合新人的入门任务类型，为新手任务筛选提供了数据支撑。

在新人支持工具方面，Steinmacher 等人^{[2][3]}提出了 FLOSScoach 门户系统，基于 58 项入门障碍模型，设计了包含贡献流程、任务列表、沟通指南的一站式支持平台。实验表明，该系统能显著降低新人的流程与社交障碍，使用 FLOSScoach 的开发者完成率达 77%，显著高于对照组的 56%。但该系统存在明显局限性：仅提供通用化指南，无法实现个性化任务匹配；未解决环境搭建、代码理解等核心技术障碍；缺乏对开发者成长过程的持续跟踪与引导。

2.2 代码语义建模与任务推荐技术

随着深度学习的发展，代码语义建模与个性化推荐技术为开源任务匹配提供了新的解决方案。

Feng 等人^[4]提出的 CodeBERT 是首个支持多编程语言的预训练模型，通过"掩码语言建模+替换词检测"混合目标，在自然语言代码搜索、代码文档生成等任务上取得了 SOTA 效果，为代码语义理解奠定了基础。在此基础上，Jin 等人^[5]提出了 CODER 代码推荐框架，首次将代码语义、项目层级

结构与用户多行为数据融合到异构图模型中。该框架通过：（1）CodeBERT 编码代码片段语义，结合历史贡献者特征生成文件表示；（2）构建文件-目录-项目层级图，聚合结构信息增强表示；（3）联合建模用户-文件微观贡献与用户-项目宏观交互行为，实现精准的代码文件推荐。实验表明，CODER 在机器学习、全栈、数据库三个领域的数据集上，相比最优基线 NDCG@20 提升了 17.9%-37.1%，在冷启动用户场景下提升更为显著。但该框架仅关注已有贡献者的文件推荐，未考虑开发者的成长阶段差异，也未设计从入门到进阶的阶梯式成长路径。

2.3 现有研究的局限性

综合来看，现有研究仍存在以下不足：

- 任务匹配缺乏个性化：多数研究停留在统计分析层面，未结合开发者个体能力与兴趣进行精准匹配，导致任务太难做不了或任务太简单没成长的问题；
- 成长路径缺失：现有工具仅关注首次贡献的单点支持，缺乏对开发者全生命周期的跟踪与引导，无法帮助新人逐步成长为核心贡献者；
- 技术融合不充分：代码语义建模与图神经网络、大模型等技术尚未充分融合应用于开源任务推荐，无法深度理解任务的技术难度与开发者的技术能力匹配度；
- 系统落地性不足：多数研究停留在算法验证阶段，未形成完整的、可直接部署的开源贡献导学系统。

3. 研究意义

3.1 理论意义

- 丰富开源开发者成长建模理论，提出融合时序行为、技术栈、协作能力的多维度成长画像体系，为开发者能力评估提供新的量化方法；
- 提出结合代码语义、项目结构与开发者成长阶段的任务匹配模型，拓展了个性化推荐技术在开源领域的应用；
- 构建从入门到进阶的阶梯式成长路径设计方法，为开源社区人才培养提供理论指导。

3.2 应用意义

- 降低入门门槛：为零基础开发者提供低门槛、高成功率的入门任务与清晰的贡献流程，帮助更多人参与开源；
- 提升留存率：通过个性化引导与阶梯式成长路径，增强开发者的成就感与归属感，提升长期留存率；
- 赋能开源项目：帮助项目维护者快速筛选合适的贡献者，降低沟通与审核成本，提升项目开发效率；
- 促进生态发展：培养更多高质量开源人才，推动我国开源生态的健康可持续发展，增强我国在全球开源领域的话语权。

参考文献：

- [1] Vikram N. Subramanian. 2020. An empirical study of the first contributions of developers to open source projects on GitHub. In *Proceedings of the ACM/IEEE 42nd International Conference on Software Engineering: Companion Proceedings* (ICSE '20). ACM, New York, NY, USA, 116–118. <https://doi.org/10.1145/3377812.3382165>
- [2] Igor Steinmacher, Tayana Uchoa Conte, Christoph Treude, and Marco Aurélio Gerosa. 2016. Overcoming open source project entry barriers with a portal for newcomers. In *Proceedings of the 38th International Conference on Software Engineering* (ICSE '16). ACM, New York, NY, USA, 273–284. <https://doi.org/10.1145/2884781.2884806>
- [3] Igor Steinmacher, Igor Scaliante Wiese, Tayana Conte, Marco Aurélio Gerosa, and David Redmiles. 2014. The hard life of open source software project newcomers. In *Proceedings of the 7th International Workshop on Cooperative and Human Aspects of Software Engineering* (CHASE 2014). ACM, New York,

NY, USA, 72–78. <https://doi.org/10.1145/2593702.2593704>

[4] Zhangyin Feng, Daya Guo, Duyu Tang, Nan Duan, Xiaocheng Feng, Ming Gong, Linjun Shou, Bing Qin, Ting Liu, Daxin Jiang, and Ming Zhou. 2020. CodeBERT: A Pre-Trained Model for Programming and Natural Languages. In *Findings of the Association for Computational Linguistics: EMNLP 2020*. Association for Computational Linguistics, Online, 1536–1547.

[5] Yiqiao Jin, Yunsheng Bai, Yanqiao Zhu, Yizhou Sun, and Wei Wang. 2023. Code Recommendation for Open Source Software Developers. In *Proceedings of the ACM Web Conference 2023 (WWW '23)*. ACM, New York, NY, USA, 1324–1333. <https://doi.org/10.1145/3543507.3583503>

三、研究内容、拟解决的关键问题、研究方法

1. 研究内容

本项目面向“开源社区准入门槛高、贡献任务难匹配、开发者成长缺乏系统引导”等痛点，研发“OSS-Mentor：基于开发者成长画像的开源贡献导学系统”。系统以开发者成长画像为核心，以开源贡献任务理解与能力需求建模为纽带，形成“画像构建 → 新手破冰 → 进阶导航 → 示范应用”的闭环导学机制，为不同阶段开发者提供从入门到进阶的阶梯式实践路径，最终实现降低开源入门门槛、提升贡献成功率与留存率、促进开源协作效率的目标。

1.1 总体框架

项目整体分为四层技术架构：

- 数据层：采集 GitHub 开发者时序行为数据（Commit、PR、Issue、Review、协作关系等）与项目结构数据，完成清洗、脱敏与标准化，构建时序化数据集。
- 表征层：构建两类核心表示模型，分别是开发者成长画像表征（能力、经验、贡献风格、成长轨迹）和贡献任务表征（任务语义、代码特征、难度与能力需求）。
- 决策层：面向不同阶段开发者提供两级导学服务，新手破冰实现入门任务精准匹配，进阶导航基于 CodeBERT、GNN 和大模型等技术 实现高成长收益的任务推荐。
- 应用层：依据贡献结果（合并状态、耗时、返工、互动情况）动态更新画像与推荐策略，完成系统开发，搭建示范应用。

1.2 研究内容一：开发者成长画像构建

本项目以开发者在开源社区的时序行为数据为基础，构建多维度、可解释、动态演进的开发者成长画像，实现对开发者能力与成长阶段的量化刻画。通过采集开发者全场景活动数据，完成时序化行为序列的构建；从开源经验、技术栈、贡献类型、协作能力、贡献质量五个维度建立可解释的画像特征指标体系；基于里程碑事件与行为特征，自动划分新手、初级、中级、进阶四类开发者成长阶段；最终将画像以向量表示与标签体系形式输出，支持动态更新与统一接口调用，为后续任务匹配提供核心支撑。

1.3 研究内容二：新手破冰——入门级贡献任务识别与匹配

本项目聚焦开发者首次贡献场景，通过实证分析挖掘新手入门规律，构建低门槛任务识别与匹配机制，重点解决新人开源贡献冷启动问题。通过统计分析任务类型、改动规模、贡献成功率与失败原因，提炼出可复用的开发者入门规律；明确文档修复、轻量 Bug 修复、测试补充等入门任务范畴，并从多维度完成入门任务的难度分级；依据开发者成长画像实现入门任务精准推荐，同时配套生成贡献流程、规范要求与沟通建议，全面提升新手首次贡献的体验与成功率。

1.4 研究内容三：进阶导航——基于深度表征的任务推荐与阶梯路径规划

本项目面向已完成首次贡献的开发者，构建以能力提升为核心目标的进阶任务推荐与阶梯式成长路径规划方案。借鉴 CODER 框架，利用 CodeBERT 完成代码语义建模，利用图神经网络 GNN 和大模型等技术完成项目结构与依赖关系建模，实现进阶任务的深度表征；以适度挑战、技能扩展、可解释为原则，设计面向学习增益的任务推荐策略，为开发者推荐能有效提升能力的进阶任务；构建任务—能力关联图，生成分阶段成长路线，并根据开发者实际贡献反馈动态调整路径，实现阶梯式能力成长引导。

1.5 研究内容四：系统实现与评测

本项目完成 OSS-Mentor 原型系统研发与实验验证，形成可持续迭代优化的闭环导学系统。开发系统前后端功能模块，实现开发者画像展示、个性化任务推荐、阶梯式成长路径呈现与导学提示推送等核心功能；设计多维度评测方案，通过离线指标与首贡成功率、开发者留存率等真实用户行为指标，与传统推荐方法开展对比实验，验证系统的有效性与优越性。

2. 拟解决的关键问题

2.1 关键问题一：开发者成长画像的多维建模与冷启动初始化问题

画像构建面临两个核心困难。其一是多维融合与可解释性难以兼顾，系统需从开发者 GitHub 时序行为数据中同时提取开源经验、技术能力、贡献类型、协作沟通、质量稳定性五个维度的异构特征并融合为统一画像，不同维度间存在潜在冲突——高贡献频率不等于高代码质量，PR 合并率高不等于技术深度强——如何在保证画像向量表达能力的同时维持各维度可解释性，使系统能够清晰说明“你在哪个方向擅长、哪个方向有待提升”，是画像构建的核心技术难题。其二是零经验新手的冷启动问题，系统最需要服务的用户群体恰恰是历史数据最匮乏的群体，无贡献记录导致画像无从构建，推荐引擎陷入“无据可推”的困境。

针对多维融合问题，建立“能力—经验—协作”三类指标体系，对各维度特征归一化后加权融合生成统一画像向量，权重参考 Subramanian 等人（2020）实证发现，同时输出可解释维度评分与关键行为摘要，实现计算效率与可解释性的统一。针对冷启动问题，采用结构化能力自评问卷结合 GitHub 间接信号——公开仓库语言构成、Star 项目主题标签等浅层行为数据——共同完成初始画像构建，确保零贡献用户也能获得具有参考价值的初始画像。

2.2 关键问题二：入门级贡献任务的客观量化界定与分级标准建立问题

GitHub 上“good first issue”标签完全依赖维护者主观判断，不同项目对“入门”的理解差异悬殊，标签质量参差不齐，直接按标签筛选命中率偏低。更根本的问题在于，任务难度是多维度概念，单一维度评估必然产生偏差：同样修改 10 行代码，对没有对应语言基础的开发者可能极度困难，而一个变更 50 行但配有详尽文档和完整测试用例的任务，对有基础的开发者反而相对友好。因此系统需要构建覆盖代码变更规模、模块耦合度、CI 构建门槛、社区友好度等多维度的客观评估体系，同时输出标准化任务画像和能力需求清单，为精准匹配提供结构化依据。

以 Subramanian 等人（2020）实证结论为量化基准，将“中位变更行数 15 行以内、单文件修改”作为入门级任务的核心参数，在此基础上扩展实证研究样本范围，分析首次 PR 的任务类型、改动规模、文本复杂度与合并成功率之间的统计关系，形成可量化的入门规律。综合任务文本复杂度、模块耦合度、CI 构建门槛、历史 PR 统计特征等多维指标构建难度评估模型，输出标准化任务画像与能力需求清单，替代对主观标签的简单依赖。

2.3 关键问题三：进阶任务的深度语义理解与“学习增益”导向推荐问题

本问题包含两个紧密关联的子挑战。一是“学习增益”导向推荐目标的量化实现，进阶导航强调推荐“难度略高于当前能力、能逐步扩展技能覆盖”的任务，而非单纯推荐最容易完成的任务，但“学习增益”本身是抽象概念，缺乏现成的可计算定义，若定义不准确则系统退化为普通相似任务推荐，失去教育导向的核心价值。二是阶梯式成长路径的合理性保证，系统需为开发者构建以 3 至 5 个任务为一阶段的递进序列，任务之间需在能力需求上形成合理的依赖与递进关系，如何在任务空间中建立能力依赖图并规划出逻辑连贯的成长路径，涉及图结构建模与路径搜索的算法设计。

针对学习增益量化问题，将其操作化定义为推荐任务在技术栈上与开发者已有能力存在“相邻扩展”关系，同时难度评分位于当前能力的合理上浮区间，在推荐打分函数中引入“能力牵引因子”，区别于单纯最大化完成概率的效率导向推荐。针对路径规划问题，基于任务的能力需求清单以“能力维度向量”为节点构建任务关系图，将任务间的能力需求相似性和递进关系建模为图的边权重，通过启发式路径搜索生成符合个人画像的阶梯式成长路径。

3. 研究方法

本项目采用实证研究、深度学习建模、启发式算法优化与原型系统验证相结合的混合研究方法，具体如下：

3.1 大规模实证分析法

针对“入门级任务量化界定”这一核心问题，本项目将基于 GitHub 公开数据集开展大规模实证研究：

- 数据驱动的特征提取：通过对数以万计的首次贡献（FirstPR）进行统计分析，提取包括代码修改行数（LoC）、涉及文件数、讨论轮次、CI 失败率等量化指标。
- 基准建立：以 Subramanian 等人的研究为基础，建立一套客观的“新手友好度”评价模型，

改变以往单纯依赖主观标签（如 good first issue）的现状，为后续的精准确匹配提供数据支撑。

3.2 多源异构数据融合建模法

针对“开发者成长画像”的构建，本项目采用多维特征融合技术：

- 时序行为建模：利用长短期记忆或 Transformer 机制处理开发者在 GitHub 上的时序行为数据（如 Commit 频率、Issue 活跃度等），捕捉其能力演进轨迹。
- 特征工程与降维：从开源经验、技术栈、协作能力等五个维度提取特征，利用归一化加权融合算法构建统一的向量表征，同时结合结构化能力自评问卷解决新手的“冷启动”问题。

3.3 基于深度学习的代码语义表征法

在“进阶任务导航”部分，本项目利用最前沿的 AI 技术提升推荐的精准度：

- 预训练模型应用：借鉴 CodeBERT 等预训练模型，对开源任务的 Issue 文本描述和代码变更进行深度语义编码，实现任务需求与开发者技术能力的语义级对齐。
- 图神经网络（GNN）建模：构建“开发者-项目-任务”异构图，利用 GNN 捕捉项目内部的模块依赖关系和开发者间的协作网络，增强推荐模型对项目结构的理解力。

3.4 启发式路径规划与优化算法

针对“阶梯式成长路径”的设计：

- 学习增益量化：在推荐算法中引入“能力牵引因子”，将推荐目标从单纯的“任务完成概率最大化”转向“学习增益最大化”。
- 图搜索算法：将任务空间建模为能力依赖图，利用改进的启发式搜索算法或强化学习策略，为开发者规划出逻辑连贯、难度梯度合理的 3-5 阶段成长路径。

3.5 原型系统开发与对比实验法

闭环系统工程：

- 采用前后端分离架构开发 OSS-Mentor 原型系统，集成数据采集、画像展示、任务推荐与反馈闭环功能。

多维度评测方案：

- 离线实验：在标准数据集上对比本项目算法与 CODER 等基准模型在 NDCG@K、MRR 等指标上的表现。
- 在线指标/用户实验：通过真实的 PR 合并成功率、开发者留存率等指标验证系统在降低门槛、促进成长方面的实际应用效果。

四、项目特色与创新点

1. 以“学习增益”为优化目标

以“学习增益”为优化目标，实现从“兴趣匹配”到“成长驱动”的范式转变。现有工作（包括 CODER）的本质是兴趣匹配，即找到用户可能感兴趣的文件或项目，而 OSS-Mentor 明确提出以学习增益（Learning Gain）为核心优化目标，推荐的不是“最可能点击的”，而是“最有利于成长的”。这一根本性转变带来了评测体系、推荐目标函数、路径规划逻辑的系统性重设计——在传统 NDCG@K、Hit@K、MRR@K 之外，新增难度适配率与技能多样性覆盖度两类专为导学目标设计的指标，确保推荐任务难度落在用户能力合理上浮区间且技术栈覆盖具备渐进性。与之配套的是开发者成长轨迹的时序建模与“渐进跃迁”的双模块自适应衔接机制：系统保留行为的时间戳、间隔与里程碑事件，刻画“开发者是如何一路成长到这里的”，从而识别出“快速成长期新人”与“长期停滞者”两类截然不同的用户；当画像显示用户接近跃迁条件时，系统通过“试探—确认—切换”机制混入少量进阶任务，以真实交互行为验证判断后再逐步切换策略，避免“突然升级”带来的挫败感。这一完整链条构成了目前开源推荐领域尚无现成解决方案的开放性问题。

2. 解决冷启动难题

解决冷启动难题并实现任务难度的客观量化，为新手群体提供有据可依的推荐基础。针对新手群体历史数据最稀少这一核心挑战，OSS-Mentor 设计了两级冷启动方案：以结构化能力自评问卷作为画像初始化的主动信号，同时从公开仓库语言构成、Star 的项目主题标签等浅层行为数据中挖掘补充特征，确保零贡献记录的用户也能获得有意义的推荐而非系统拒绝服务。在任务端，系统将 Subramanian（2020）的实证结论系统性地转化为工程参数，以“中位变更行数 15 行以内、单文件修改”为入门级基准，进一步扩展为覆盖代码行数、文件波及范围、CI 失败率、前序讨论轮次等多维度的客观难度评分体系，输出标准化的任务画像与能力需求清单，突破了直接依赖 good first issue 标签时质量参差不齐、主观性强的局限。基于此构建的任务关系图以能力需求向量为节点属性，边权重编码能力递进关系，为阶梯式路径规划提供可计算的底层基础，形成从画像初始化到任务分级的完整冷启动闭环。

3. 反馈信号的差异化加权与闭环更新机制

反馈信号的差异化加权与闭环更新机制，提升系统对噪声数据的鲁棒性。PR 反馈信号本质上是有噪声的——被拒绝可能因代码质量问题，也可能因项目方向变动等无关因素。OSS-Mentor 设计了三级可靠性加权方案：PR 成功合并作为高可靠性正向信号赋予高权重，PR 被关闭或拒绝则需结合上下文判定为弱负向信号赋予中低权重，浏览或收藏但未提交仅作为偏好信号赋予低权重。这一设计比直接用合并/未合并做二分标签更为鲁棒，是 CODER 等现有工作未涉及的工程细节。在此基础上，基于 PR 结果的反馈闭环机制动态更新开发者画像与推荐策略，使系统能够持续追踪用户成长状态变化，实现推荐质量的迭代优化。该方案与前述两级冷启动方案、任务难度客观量化体系协同配合，构成了面向开源新手导学场景中数据处理与系统更新的完整方法论。

五、项目研究进度与计划

文献查阅、社会调查、方案设计、实验研究、数据处理、研制开发、撰写论文或研究报告、结题和答辩、项目鉴定、成果推广或论文发表、其他等环节的时间安排

1. 2026 年 5 月至 6 月：启动与方案设计阶段

重点开展文献查阅工作，深入研读国内外关于开源新人贡献障碍、推荐算法及代码语义建模的相关文献。在此基础上，进一步完善 OSS-Mentor 系统的总体技术架构设计，细化包含开源经验、技术栈、协作能力等五个维度的开发者成长画像指标体系，并搭建基础的软硬件实验环境与开发框架。

2. 2026 年 7 月至 8 月：数据处理与实证研究阶段

开展针对开源新人贡献特征的社会调查与实证研究，利用 GitHub API 采集开发者时序行为数据及项目结构数据，并完成数据清洗、脱敏与标准化处理。基于 Subramanian 等人的研究结论，本项目将扩展实证样本范围，通过统计分析任务类型、改动规模与合并成功率的关系，提炼可量化的入门规律，为后续构建任务分级标准提供实证支撑。

3. 2026 年 9 月至 11 月：算法研发与实验研究阶段

聚焦核心算法与模型的研制开发，利用 CodeBERT 完成代码语义建模，并结合图神经网络（GNN）与大模型技术实现进阶任务的深度表征。同步开发开发者成长画像服务，实现多维画像向量的输出与动态演进功能。此外，本阶段还将研究基于任务—能力关联图的路径规划算法，设计以“学习增益”为核心的阶梯式成长路径生成方案。

4. 2026 年 12 月至 2027 年 2 月：系统研制与集成阶段

全面推进 OSS-Mentor 原型系统的开发工作，构建可视化可交互的 Web 平台。开发内容包括 GitHub OAuth 登录模块、个人画像展示模块、个性化任务推荐模块以及阶梯式路径引导模块。同时，集成基于 PR 结果的反馈闭环机制，根据开发者真实的合并状态与互动情况，动态更新画像权重与推荐策略。

5. 2027 年 3 月至 4 月：对比实验与论文撰写阶段

开展系统的实验研究与性能评估。通过离线指标与真实用户行为指标（如首贡成功率、留存率等）开展对比实验，验证系统在降低开源门槛方面的优越性。同时，整理研究成果，撰写并发表 1 至 2 篇关于开源导学系统的学术论文，并完成完整的研究报告与专利/软件著作权申报材料。

6. 2027 年 5 月：结题答辩与成果推广阶段

进行项目的最终鉴定与结题准备工作，整理项目交付物，包括 OSS-Mentor 原型系统、实证数据集及算法模型成果。参加项目结题答辩，汇报研究目标的完成情况。最后，开展成果推广工作，通过示范应用验证系统在提升开源协作效率与培养人才方面的实际意义。

六、项目预期成果

- 成果形式：论文、设计、产品研制、软件开发、专利、研究或调研报告、课件等
1. 核心系统交付物：OSS-Mentor 原型系统
- 本课题的核心系统交付物为 OSS-Mentor 原型系统，该系统完整实现了“数据层→表征层→决策层→反馈层”四层架构，支持离线训练与在线查询的无缝切换。具体而言，系统包含四大功能模块：开发者成长画像服务，可输出多维画像向量、可解释维度评分及关键行为摘要；新手破冰推荐模块，负责入门任务的自动识别、匹配与导学提示生成；进阶导航推荐模块，通过深度语义任务理解实现学习增益导向的精准推荐；阶梯式路径规划模块，能以 3 至 5 个任务为一阶段生成个性化成长路线，并配合基于 PR 结果的反馈闭环机制，动态更新画像与推荐策略。
2. 数据集与实证研究成果
- 在数据集与实证研究方面，本课题将在 Subramanian（2020）的基础上，系统性地扩展首次贡献实证研究，构建一套覆盖更大样本量、更多特征维度的首贡数据集。通过对任务类型、改动规模、讨论轮次与 PR 合并成功率之间关系的深度挖掘，提炼出清晰的量化规律，并据此产出一套可量化的入门任务分级标准，突破现有对"good first issue"标签的单一依赖，为开源社区的任务治理提供实证支撑。
3. 模型与算法成果
- 在模型与算法层面，本课题将产出三项关键成果：一是融合“能力—经验—协作”三类五维度特征的开发者成长画像模型，具备完善的冷启动初始化机制；二是任务难度量化模型，通过多维度客观评分体系，输出标准化的任务画像与能力需求清单；三是任务关系图，以能力需求向量为节点属性构建任务图，将边权重编码为能力递进关系，为阶梯式路径规划提供底层计算基础。
4. 知识产权成果
- 在知识产权成果方面，本课题拟发表论文 1 至 2 篇，系统阐述面向开源社区的新手开发者导学推荐方法，覆盖 OSS-Mentor 原型系统的全部功能模块。
5. 可视化可交互 web 平台成果
- OSS-Mentor 平台主体为一个 web 网站，通过 GitHub OAuth App 登录至 Github。
- 用户登录后，平台自动抓取其公开的提交记录、PR 历史与项目参与数据，从五个维度生成可视化的个人成长画像，并基于画像实时推荐难度匹配、学习价值最高的开源贡献任务，同时为每位用户规划一条从新手破冰到核心贡献者的阶梯式成长路线——让开发者在每一次贡献中都能看见自己的成长轨迹。

七、项目指导教师情况

姓名	性别	职称	研究方向	手机	E-mail
陆雪松	男	副教授	数据驱动的计算教育学	18721010041	xslu@dase.ecnu.edu.cn

八、项目组成员

姓名	学号	年级	专业	项目研究中承担主要任务	签名
朱翎融	10245501401	2024 级	数据科学与大数据技术	项目统筹与核心建模设计：负责项目整体技术路线规划与架构选型；主导“开发者成长画像”多维指标体系的设计与量化算法实现；负责定义各层级间的数据接口规范与系统集成逻辑。	朱翎融
白淑静	10245501436	2024 级	数据科学与大数据技术	数据工程与语义表征研发：负责 GitHub 全场景行为数据的自动化采集、清洗与脱敏；利用 CodeBERT 与 GNN 构建贡献任务的深度语义表征模型，并完成模型在 GPU 集群上的微调与参数优化。	白淑静
龚晓博	10245501469	2024 级	数据科学与大数据技术	后端架构与安全工程实现：负责 OSS-Mentor 服务端（API）开发、数据库模式设计与高性能检索优化；实现 GitHub OAuth 第三方登录集成；负责系统的部署与运维。	龚晓博
李颖珊	10245501444	2024 级	数据科学与大数据技术	前端交互开发与实验测评：负责 Web 平台响应式界面开发与开发者画像可视化组件实现；负责采集并分析首贡成功率、留存率等量化指标，验证推荐策略的实际效能。	李颖珊

九、项目经费预算

支出项目名称	金额（元）	测算依据及用途
规模数据采集与预处理	1500	用于构建 GitHub 开发者时序行为数据集。包含利用 GitHub API 进行大规模数据抓取时的代理服务费用、时序行为序列清洗与脱敏算法的存储开销，以及构建标准化实证数据集的硬件存储扩容。
深度表征模型训练与算力租赁	2500	用于支持 CodeBERT 代码语义建模、图神经网络（GNN）以及大模型微调的计算需求。主要支出为租用高性能 GPU 云服务器进行模型训练、任务表征向量生成及进阶路径规划算法的迭代优化。
系统架构开发与云端部署	1500	用于 OSS-Mentor 原型系统的开发。包含 Web 前后端框架搭建、GitHub OAuth 第三方登录集成、开发者成长画像可视化组件研发，以及导学提示推送系统的云端服务器部署与域名运维。
合计	5500	


十、项目研究所需资源

拟依托的实验室或研究中心等机构、拟使用的仪器设备及其他 拟依托华东师范大学全民数字素养与技能培训基地（国家级），为本项目提供先进的数据科学实验环境与大规模开源社区数据处理的基础设施支撑。 拟使用英伟达 A800 及以上型号的 GPU，保障 CodeBERT 预训练模型微调与复杂图神经网络模型的高效迭代训练。

十一、申请人承诺

本人保证申请书内容的真实性。如果获得资助，我将履行项目负责人职责，严格遵守经费使用的有关规定，切实保证研究工作时间，积极组织开展研究工作，合理安排研究经费，按时报送有关材料并接受检查。若填报失实和违反规定，本人将承担全部责任。 签名：朱翎融 2026 年 5 月 9 日
--

十二、审核意见

指导教师意见	该项目选题面向开源社区开发者入门难、任务匹配不精准、成长路径规划难等挑战，综合运用开发者画像、CodeBERT、图神经网络与大模型等前沿技术，设计解决方案，创新性与可行性较强，研究目标明确、应用价值突出。 项目组成员为数据科学与大数据技术专业本科生，专业基础扎实、分工合理，具备完成本项目所需的编程、数据处理与系统开发能力。研究进度安排合理，预期成果明确，符合本科生创新训练培育项目要求。 综上，同意推荐本项目立项，请考虑予以支持。 指导教师（签字）： 2026 年 5 月 9 日
院系（学部）意见	负责人（签字）： 单位公章： 年 月 日
学校意见	负责人（签字）： 单位公章： 年 月 日